



MODUL PERKULIAHAN

OPTIMALISASI & OTOMASI

Kode Mata kuliah P132520004

Modul 1

Pengantar Time Series Data

Abstrak

Pertemuan ini membahas akuisisi data time series sensor industri: teorema sampling Nyquist-Shannon, bahaya

Sub - CPMK


Sub-CPMK 1.1 – Mampu mengidentifikasi komponen dan kebutuhan teknis sistem otomasi

Disusun Oleh :
Dedik Romahadi, ST., M.Sc

 **Modul Interaktif:** <https://dedik-romahadi.github.io/Mechanical-Engineering-Courses/Optimalisasi-dan-Automasi/Modul/Modul-1.html>. Pada layar masuk, pilih tombol “ Mode Preview (Tanpa Login)” untuk melihat modul lengkap (animasi, kalkulator interaktif, editor kode Python langsung di browser) tanpa perlu akun. Soal pada Mode Preview bersifat tampilan saja; jawaban benar/salah dan poin tidak aktif.

PENDAHULUAN

Pertemuan pertama ini adalah pintu gerbang ke seluruh mata kuliah Optimalisasi & Otomasi. Sebelum dapat memprediksi kerusakan mesin, mengoptimalkan jadwal perawatan, atau mengotomasi keputusan operasional, mahasiswa harus terlebih dahulu memahami karakter data yang dihasilkan oleh sensor industri: data berurutan dalam waktu, atau time series. Setiap pengukuran getaran, suhu, arus, maupun aliran yang diambil dari mesin memiliki cap waktu, sehingga ketergantungan antar waktu inilah yang membedakannya dari data tabular biasa. Gambaran umum alur pembahasan pertemuan ini, dari akuisisi sensor mentah hingga keputusan teknis, ditunjukkan pada Gambar 1.



Gambar 1. Alur pertemuan 1: dari akuisisi sensor mentah menjadi keputusan condition monitoring.

Modul ini membahas teori sampling (Teorema Nyquist-Shannon), frekuensi Nyquist, dan bahaya aliasing ketika sampling rate kurang memadai, lalu memperkenalkan metrik dasar getaran (RMS, peak, crest factor, SNR) serta klasifikasi severity ISO 10816 sebagai fondasi

condition monitoring. Materi ditutup dengan implementasi Python di Jupyter Notebook, tugas terstruktur, dan forum diskusi studi kasus.

Capaian Pembelajaran (Sub-CPMK)

- **Sub-CPMK 1.1:** Mampu mengidentifikasi komponen dan kebutuhan teknis sistem otomasi, yaitu menentukan sampling rate, jenis sensor, dan strategi penyimpanan data yang dibutuhkan untuk akuisisi deret waktu, dengan mempertimbangkan trade-off antara kualitas data dan biaya (CPMK 1).
- Setelah pertemuan ini mahasiswa dapat: menjelaskan sifat temporal dependency pada time series; menguraikan komponen tren, musiman, siklik, dan noise; menghitung lima statistik dasar sinyal; memilih sampling rate yang benar berdasarkan Teorema Nyquist; serta mengimplementasikan semuanya dengan NumPy/Pandas.

KONSEP DASAR TIME SERIES

Time series adalah urutan observasi terhadap indeks waktu $t = 1, 2, \dots, N$, dinotasikan $\{x_t\}$. Berbeda dengan data biasa (misalnya tabel pelanggan), urutan dalam time series adalah informasi: mengacak urutannya menghancurkan makna. Setiap titik x_t berhubungan dengan x_{t-1} , x_{t-2} , dan seterusnya; sifat inilah yang disebut temporal dependency. Hubungan ini dirangkum dalam Persamaan (1).


$$x_t \approx f(x_{t-1}, x_{t-2}, \dots) \quad (1)$$

Sensor sebagai Sumber Data

Mesin industri modern memiliki ratusan sensor: akselerometer (getaran), termokopel (suhu), strain gauge (regangan), sensor arus motor, dan sensor tekanan oli. Semuanya menghasilkan time series. Frekuensi sampling menentukan resolusi data: getaran high-speed bisa memerlukan 10 kHz, suhu cukup 1 Hz, dan kondisi proses cukup satu sampel per menit. Periode sampling dirumuskan $\Delta t = 1/f_s$. Gambar 2 menunjukkan contoh sinyal getaran sintesis hasil superposisi tiga komponen frekuensi ditambah noise, yaitu pola yang tipikal terekam akselerometer pada motor industri.

Pemilihan jenis sensor juga mempertimbangkan aspek ekonomi: akselerometer piezoelectric presisi tinggi untuk vibration monitoring bisa berharga jutaan rupiah per unit ditambah biaya instalasi dan kalibrasi berkala, sedangkan termokopel tipe K jauh lebih murah dan tahan lingkungan panas ekstrem. Pada sistem dengan puluhan hingga ratusan titik ukur, keputusan menempatkan sensor mahal hanya pada komponen kritis seperti bearing utama dan gearbox, sementara komponen sekunder cukup dipantau tidak

langsung, adalah trade-off ekonomi khas yang akan terus muncul sepanjang mata kuliah ini.



Gambar 2. Sinyal getaran sintetis: superposisi tiga komponen frekuensi (25, 60, 120 Hz) ditambah noise Gaussian.

Pola Periodik

Banyak sinyal mesin bersifat periodik, seperti getaran berulang setiap rotasi poros, suhu naik-turun mengikuti shift kerja, beban bergeser sesuai musim produksi. Memahami periode dan amplitudo sinyal periodik $x(t) = A \cdot \sin(2\pi ft + \phi)$ adalah dasar untuk semua analisis lanjutan: FFT, deteksi anomali, dan prediksi. Pada Gambar 2 komponen 25 Hz terlihat sebagai pola dominan yang berulang setiap 40 ms, dengan dua komponen frekuensi lebih tinggi (60 dan 120 Hz) menumpangi bentuknya.

Noise dan Sinyal Tercampur

Pengukuran sensor selalu mengandung noise: getaran liar, gangguan elektromagnetik, dan drift sensor. Kemampuan memisahkan sinyal sejati dari noise adalah keterampilan inti seorang engineer data. Rasio sinyal terhadap noise, $SNR = 10 \cdot \log_{10}(P_{\text{sinyal}}/P_{\text{noise}})$, menentukan apakah pola dapat dideteksi atau tertutup derau.

Prinsip utama: Time series bukan sekadar deretan angka; ia adalah jejak digital dari fenomena fisik yang sedang berjalan. Setiap angka adalah potret kondisi mesin pada satu waktu; dengan menyusunnya berurutan diperoleh cerita tentang perilaku mesin, dan dari cerita itulah keputusan teknis diambil: kapan service, kapan mengganti spare part, kapan melakukan optimasi.

KOMPONEN SINYAL TIME SERIES

Setiap deret waktu dari sensor industri pada dasarnya adalah jumlah beberapa komponen tersembunyi. Memahami komponen-komponen ini penting agar data tidak salah dibaca: lonjakan getaran tiba-tiba bisa berarti kerusakan, atau hanya pola harian yang muncul setiap pergantian shift pagi. Model aditifnya, divisualisasikan pada Gambar 3, adalah: Bentuk ringkasnya dituliskan pada Persamaan (2).

$$yt = Tt + St + Ct + \epsilon t \quad (\text{observasi} = \text{tren} + \text{musiman} + \text{siklik} + \text{noise}) \quad (2)$$

- **Tren (Tt):** pergerakan jangka panjang yang tidak berulang (naik, turun, atau datar). Pada bearing, getaran rata-rata yang naik selama berbulan-bulan menandakan aus progresif. Tren bisa linear, eksponensial (kerusakan cepat), atau logaritmik (degradasi melambat). Panel kedua Gambar 3 menunjukkan tren linear naik pada deret harian sintetis.
- **Musiman (St):** pola berulang berperiode tetap yang terkait kalender/jadwal: konsumsi listrik tinggi pukul 08.00–17.00 (harian), produksi turun tiap akhir pekan (mingguan), maintenance terjadwal awal bulan (bulanan). Berlaku $St+s = St$ dengan periode s diketahui dari konteks operasional; lihat osilasi berperiode 7 hari pada panel ketiga Gambar 3.
- **Siklik (Ct):** pola berulang tanpa periode tetap, seperti fluktuasi ekonomi dan siklus permintaan industri. Tidak terikat kalender sehingga lebih sulit ditangkap; sering digabung dengan tren saat dekomposisi.
- **Residual/Noise (ϵt):** sisa acak setelah tren, musiman, dan siklik dipisahkan; idealnya white noise $\epsilon t \sim N(0, \sigma^2)$: mean nol, varians konstan, tanpa autokorelasi. Anomali nyata muncul sebagai residual besar yang menyimpang dari distribusi normalnya (lihat panel terbawah Gambar 3).


Tabel 1 merangkum keempat komponen tersebut sekaligus, lengkap dengan periode khasnya, contoh kemunculan di industri, dan metode deteksi yang lazim dipakai untuk masing-masing.

Kesalahan yang sering terjadi di lapangan adalah menganggap kenaikan sebuah statistik sebagai anomali tunggal, padahal sesungguhnya gabungan dua komponen berbeda yang kebetulan naik bersamaan. Misalnya, RMS getaran yang meningkat menjelang akhir shift malam bisa jadi bukan indikasi kerusakan, melainkan superposisi tren aus bearing dengan pola musiman beban produksi yang memang lebih tinggi pada jam tersebut. Tanpa dekomposisi, engineer berisiko menjadwalkan maintenance yang tidak perlu, atau mengabaikan tren aus yang sesungguhnya sedang berlangsung.

Tabel 1. Empat komponen sinyal time series beserta periode, contoh industri, dan cara deteksinya.

Komponen	Periode	Contoh Industri	Cara Deteksi
Tren	Tidak ada (monoton)	Aus bearing, drift sensor, korosi pipa	Regresi linear, moving average
Musiman	Tetap (24 j, 7 h, 30 h, 365 h)	Shift kerja, weekend, musim, jadwal	FFT, dekomposisi STL, plot ACF
Siklik	Tidak tetap (> 1 tahun)	Ekonomi, permintaan pasar	Analisis spektral, model ARIMA
Noise	Acak	Kuantisasi, EMI, fluktuasi proses	Analisis residual, uji normalitas

**Dekomposisi aditif $y_t = T_t + S_t + \varepsilon_t$
pada deret harian sintesis**



Gambar 3. Dekomposisi aditif deret harian sintesis menjadi observasi, tren, musiman, dan noise.

Diagnostik visual cepat: Plot deret terhadap waktu, lalu perhatikan: (1) kemiringan jangka panjang = tren; (2) pola berulang berperiode jelas = musiman; (3) fluktuasi besar tanpa

periode = siklik atau anomali; (4) jitter halus konstan = noise. Pemeriksaan visual ini harus menjadi kebiasaan setiap menerima dataset baru.

Contoh penerapan: Pada studi kasus vibration monitoring motor conveyor pabrik semen, plot RMS harian menunjukkan kenaikan tren linear sekitar 15% selama tiga bulan, indikasi aus bearing yang progresif, namun tren ini semula tertutupi oleh osilasi musiman harian akibat pergantian shift kerja pagi-siang-malam. Baru setelah data di-smoothing dengan moving average 24 jam (menghilangkan komponen musiman), tren aus tersebut terlihat jelas dan cukup dini untuk dijadwalkan penggantian bearing sebelum kegagalan, bukan sesudahnya.

STATISTIK DASAR TIME SERIES

Sebagian besar diagnosa kondisi mesin masih dapat dilakukan dengan statistik deskriptif sederhana, jauh sebelum model machine learning diperlukan. Lima metrik fundamental berikut adalah dasar seluruh ekstraksi fitur domain waktu yang akan dibahas kembali pada Pertemuan 6. Gambar 4 mengilustrasikan bagaimana sebuah impulsive event (mis. spalling bearing) menaikkan Peak dan Crest Factor secara tajam sementara RMS relatif tidak berubah; inilah alasan Crest Factor dipakai khusus untuk deteksi dini kerusakan bearing.

- **Mean (μ):** rata-rata aritmatik $\mu = (1/N) \cdot \sum x_i$. Untuk sinyal AC seperti getaran (berosilasi di sekitar nol) mean mendekati nol, sehingga pergeseran mean menandakan DC offset atau drift sensor yang perlu dikalibrasi. Untuk sinyal DC seperti suhu, mean mencerminkan level operasional.
- **RMS:** akar dari rata-rata kuadrat, $RMS = \sqrt{(1/N) \cdot \sum x_i^2}$, yaitu ukuran energi efektif sinyal yang tidak nol meski sinyal berosilasi. Untuk monitoring getaran, RMS adalah metrik utama: ISO 10816 mendefinisikan kelas kondisi mesin berdasarkan RMS getaran (garis putus-putus hijau pada Gambar 4).
- **Standar Deviasi (σ):** ukuran sebaran data terhadap mean; untuk sinyal ber-mean nol $\sigma \approx RMS$. Nilai σ tinggi pada konteks yang biasanya stabil = variabilitas tidak normal, indikator awal kegagalan. Aturan praktis: residual melebihi 3σ dianggap outlier.
- **Peak & Crest Factor:** Peak = nilai absolut maksimum dalam jendela waktu (titik oranye pada Gambar 4); Crest Factor $CF = Peak/RMS$ sensitif terhadap impulsive event seperti benturan atau spalling bearing. Sinusoidal murni memiliki $CF = \sqrt{2} \approx 1,41$; $CF > 4$ menandakan lonjakan abnormal meskipun RMS keseluruhan masih dalam batas.

Contoh angka: Sebuah motor 15 kW yang sehat menghasilkan sinyal getaran dengan $RMS \approx 0,45$ mm/s dan $Peak \approx 0,9$ mm/s, sehingga $Crest\ Factor \approx 2,0$, khas untuk sinyal harmonik normal tanpa impulsive fault. Ketika bearing mulai spalling, $Peak$ melonjak menjadi $\approx 3,2$ mm/s sementara RMS hanya naik ke $\approx 0,52$ mm/s; $Crest\ Factor$ pun melonjak ke $\approx 6,2$, jauh di atas ambang batas 4. Inilah sebabnya $Crest\ Factor$ jauh lebih sensitif sebagai indikator dini kerusakan bearing dibanding RMS saja, yang justru menjadi metrik utama menurut ISO 10816.

Kelima statistik di atas dirangkum pada Tabel 2, dipetakan terhadap apa yang masing-masing sensitif deteksi, aplikasi tipikalnya, dan jenis kerusakan mesin yang paling relevan.


Dalam praktiknya kelima statistik ini jarang dipakai sendiri-sendiri; dashboard condition monitoring modern menghitung semuanya sekaligus pada setiap window data yang masuk, lalu menampilkannya sebagai trend chart berdampingan. Mean dan RMS memantau kondisi umum, sementara $Crest\ Factor$ menjadi early warning khusus untuk fault impulsive seperti spalling yang belum tentu terlihat dari RMS saja. Standar deviasi membantu membedakan mesin yang stabil dari mesin yang mulai tidak menentu, bahkan sebelum nilai rata-ratanya bergeser signifikan.

Tabel 2. Lima statistik dasar time series, sensitivitasnya, aplikasi, dan tipe kerusakan yang terdeteksi.

Statistik	Sensitif terhadap	Aplikasi	Tipe Kerusakan
Mean	DC offset, drift sensor	Kalibrasi, baseline	Drift sensor
RMS	Energi keseluruhan sinyal	Kelas getaran ISO 10816	Unbalance, misalignment
Std (σ)	Variabilitas, sebaran	Deteksi anomali (aturan 3σ)	Kondisi tidak stabil
Peak	Lonjakan tertinggi	Stres mekanik maksimum	Shock, impact event
Crest Factor	Impulsiveness sinyal	Diagnosa bearing	Spalling bearing, gigi gear

Untuk melihat bagaimana kelima statistik ini bereaksi terhadap kejadian nyata di lapangan, perhatikan simulasi pada Gambar 4: satu impulsive event tunggal yang mewakili awal spalling pada elemen bearing disisipkan ke tengah sinyal getaran yang sebelumnya stabil. Perhatikan bagaimana $Peak$ melonjak drastis pada saat kejadian tersebut, sementara RMS keseluruhan sinyal nyaris tidak berubah karena durasi impulsive event yang sangat singkat dibanding total durasi jendela pengukuran. Fenomena inilah yang membuat RMS saja sering kali terlambat mendeteksi kerusakan tahap awal, sedangkan $Crest\ Factor$ yang membandingkan $Peak$ terhadap RMS jauh lebih sensitif terhadap sinyal impulsive semacam ini.

Impulsive event (spalling bearing) menaikkan Peak & Crest Factor, RMS relatif stabil



Gambar 4. Peak, RMS, dan Crest Factor pada sinyal getaran dengan satu impulsive event (simulasi spalling bearing).

Window sliding untuk monitoring real-time: Hitung RMS, σ , dan CF pada window bergerak (misal 1 detik = 1024 sampel pada 1 kHz), lalu plot deret RMS bergulir terhadap waktu untuk melihat kapan kondisi mesin mulai memburuk. Window terlalu kecil = noisy; terlalu besar = lambat merespons. Praktik umum: 1 detik untuk vibration high-speed, 10 menit untuk suhu proses.

SAMPLING, FREKUENSI & TEOREMA NYQUIST

Time series dari sensor digital adalah diskretisasi sinyal kontinu di dunia fisik. Seberapa cepat sinyal harus "dipotret"? Jawabannya diberikan Teorema Nyquist-Shannon: untuk merekonstruksi sinyal berfrekuensi maksimum f_{maks} tanpa distorsi, sampling rate harus minimal dua kalinya. Memilih sampling rate yang salah berarti data sudah cacat sejak akuisisi, dan tidak ada algoritma pada pertemuan berikutnya yang mampu memperbaikinya. Gambar 5 mendemonstrasikan konsekuensinya secara visual. Persamaan (3) memadatkan aturan tersebut.

$$f_s \geq 2 \cdot f_{maks} \quad (3)$$

- **Sampling rate (f_s):** banyaknya sampel per detik (Hz). Contoh: sensor getaran 10 kHz mengambil 10.000 sampel per detik; periode sampling $\Delta t = 1/f_s$. Sampling rate menentukan resolusi waktu dan frekuensi maksimum yang dapat dideteksi.
- **Frekuensi Nyquist (f_N):** $f_N = f_s/2$, yaitu frekuensi tertinggi yang masih dapat direpresentasikan tanpa kehilangan informasi. Sampling 1 kHz hanya dapat merekonstruksi sinyal sampai 500 Hz.

- **Aliasing:** distorsi ketika komponen di atas f_N tetap masuk ke ADC: pada Gambar 5, sinyal asli 50 Hz yang di-sampling pada 60 Hz (under-Nyquist) tampak sebagai alias 10 Hz: garis oranye yang menghubungkan titik-titik sampel mengikuti gelombang palsu berfrekuensi jauh lebih rendah dari sinyal aslinya, mengikuti $f_{alias} = |f - k \cdot f_s|$. Pencegahan: pasang anti-aliasing filter (low-pass analog) sebelum ADC dengan cut-off $< f_N$.
- **Oversampling:** sampling jauh di atas Nyquist ($5\text{--}10 \times f_{maks}$). Manfaat: filter anti-aliasing lebih mudah dirancang, noise kuantisasi tersebar lalu dapat difilter, dan tersedia ruang untuk decimation. Biayanya: data lebih besar, storage dan processing lebih berat; di sinilah pertimbangan ekonomi Sub-CPMK 1.1 berperan.


Studi kasus: Sebuah pabrik pernah men-sampling getaran motor pada 2 kHz karena mengasumsikan frekuensi tertinggi yang relevan hanya 1 kHz; belakangan diketahui bearing fault BPFO mesin tersebut sebenarnya berada di 1,4 kHz, DI ATAS frekuensi Nyquist 1 kHz. Akibatnya sinyal fault teralias dan tidak pernah terdeteksi selama delapan bulan hingga terjadi kegagalan katastropik. Setelah sampling rate dinaikkan ke 10 kHz (margin sekitar $7 \times$ di atas BPFO), fault serupa pada mesin sejenis berhasil terdeteksi tiga minggu sebelum kegagalan pada siklus monitoring berikutnya.

Tabel 3 membandingkan rentang frekuensi sinyal dan sampling rate tipikal untuk lima kelompok aplikasi sensor industri yang paling umum dijumpai di lapangan.

Tabel 3. Rentang frekuensi sinyal dan sampling rate tipikal per aplikasi sensor industri.

Aplikasi Sensor	Frekuensi Sinyal	Sampling Rate Tipikal	Catatan
Suhu / tekanan	< 1 Hz	1–10 Hz	Lambat berubah, tanpa oversampling
Aliran (flow)	1–100 Hz	100 Hz – 1 kHz	Tergantung dinamika fluida
Getaran umum mesin	10 Hz – 5 kHz	10 kHz	Standar ISO 10816
Bearing high-speed	1–20 kHz	40–50 kHz	Untuk envelope analysis
Acoustic emission	50 kHz – 1 MHz	1–5 MHz	Mahal; khusus crack detection

Kolom terakhir Tabel 3 memberi catatan praktis, namun keputusan akhir tetap bergantung konteks operasional: pabrik dengan anggaran terbatas mungkin memilih titik terendah dari rentang yang direkomendasikan untuk menghemat biaya storage dan bandwidth jaringan, sementara aplikasi safety-critical seperti bearing high-speed pada turbin justru disarankan memilih titik tertinggi demi margin keamanan ekstra. Perbandingan biaya-manfaat semacam ini adalah inti dari Sub-CPMK 1.1 pertemuan ini: sampling rate bukan sekadar parameter teknis, melainkan keputusan bisnis yang memengaruhi total cost of ownership sistem monitoring.



Gambar 5. Sinyal 50 Hz yang di-sampling pada 60 Hz (under-Nyquist) tampak sebagai alias berfrekuensi 10 Hz.

Cara cepat memilih sampling rate: (1) Identifikasi frekuensi tertinggi yang relevan untuk diagnosa, biasanya characteristic frequency komponen mesin (BPFI/BPFO bearing, gear mesh); (2) kalikan minimal 5 sebagai margin keamanan; (3) pasang anti-aliasing filter analog; (4) verifikasi dengan FFT pada data contoh, pastikan tidak ada peak mencurigakan di dekat f_N .

ANALOGI KEHIDUPAN SEHARI-HARI

Enam analogi berikut (Gambar 6) menghubungkan konsep sampling & statistik sinyal dengan pengalaman sehari-hari mahasiswa, mempermudah intuisi sebelum masuk ke rumus formal.

Analogi-analogi ini sengaja dipilih dari aktivitas yang hampir setiap mahasiswa alami sehari-hari, seperti memotret dengan HP atau mendengarkan musik streaming, karena konsep sampling rate dan aliasing sering terasa abstrak ketika pertama kali dipelajari lewat rumus semata. Dengan mengaitkan $f_N = f_s/2$ pada burst mode kamera, atau RMS pada normalisasi volume Spotify, mahasiswa dapat membangun intuisi fisik terlebih dahulu sebelum kembali ke notasi matematis yang lebih formal.




Gambar 6. Enam analogi kehidupan sehari-hari untuk konsep sampling, aliasing, dan statistik sinyal.

- **Burst mode kamera HP & sampling rate:** foto burst 10 fps = sampling 10 sampel/detik. Memotret burung yang mengepak 8 kali per detik butuh burst di atas 16 fps (Nyquist); pada 5 fps kepak tampak bergerak lambat atau terbalik; itulah aliasing (lihat Gambar 6, kartu pertama).
- **Lalu lintas tol & pola musiman:** sensor gerbang tol mencatat mobil per menit selama setahun: terlihat pola harian (puncak commuter pagi-sore), mingguan (Senin–Jumat vs akhir pekan), tahunan (lebaran, libur sekolah), plus tren pertumbuhan, yaitu semua komponen time series dalam satu dataset.
- **Spotify loudness & RMS:** Spotify menormalkan volume antar lagu memakai ukuran energi RMS menuju target -14 LUFS. Logika yang sama dipakai vibration monitoring: bukan nilai puncak sesaat, melainkan energi efektif.
- **Vinyl vs MP3 & kuantisasi:** CD memakai 44,1 kHz, sesuai Nyquist untuk batas pendengaran manusia ± 20 kHz dikali dua plus margin; perbedaan yang dirasakan audiophile adalah efek kuantisasi digital.
- **EKG detak jantung & crest factor:** EKG adalah time series tegangan jantung; detak normal berpuncak P-QRS-T tegas dengan rata-rata rendah = crest factor tinggi. Aritmia mengubah CF dramatis, persis seperti bearing yang mengalami spalling (bandingkan dengan Gambar 4).

- **Cuaca BMKG & multi-resolusi:** BMKG mengukur fenomena pada resolusi berbeda: petir (milidetik) butuh sensor cepat, pergeseran musim cukup data mingguan; setiap fenomena punya characteristic frequency dan sampling rate-nya sendiri.

APLIKASI DI TEKNIK MESIN & INDUSTRI 4.0

Sampling rate tipikal naik seiring frekuensi sinyal yang harus ditangkap tiap aplikasi sensor industri (Gambar 7, skala logaritmik), mulai dari orde Hz untuk suhu/tekanan hingga orde MHz untuk acoustic emission.



Gambar 7. Sampling rate tipikal per aplikasi sensor industri (skala logaritmik).

- **Vibration monitoring motor:** akselerometer pada housing motor, sampling 10 kHz (menangkap sampai 5 kHz), cukup untuk imbalance ($1\times$ rpm), misalignment ($2\times$ rpm), dan bearing fault. Statistik per detik: RMS, peak, CF; tren RMS naik 7 hari berturut-turut memicu inspeksi.
- **Kontrol suhu proses:** termokopel oven mencatat suhu 1 Hz (suhu lambat berubah): terlihat osilasi kecil kontroler PID, pola lingkungan harian, dan event ramp-up/down. Rolling mean & std 1 menit menjadi baseline; deviasi memicu alarm.
- **Power quality energi:** sensor arus-tegangan motor 3 fasa, 25,6 kHz: fundamental 50 Hz plus harmonik. $THD = \sqrt{(\sum V_n^2)/V_1}$ di atas 5% berarti kualitas daya buruk sehingga motor cepat panas dan efisiensi turun.

- **SCADA & IoT multi-sensor:** puluhan PLC dan ratusan sensor dengan sampling rate berbeda; bandwidth terbatas → sampel tinggi di edge, hitung statistik (RMS, std), kirim hanya fitur ke cloud (edge → feature → cloud).

Kesalahan praktis yang sering terjadi: (1) sampling rate terlalu rendah → aliasing dan peak FFT palsu; (2) tanpa anti-aliasing filter → noise frekuensi tinggi masuk pita rendah; (3) time stamp tidak akurat → korelasi antar sensor keliru; (4) mengabaikan pola musiman → variasi normal dianggap anomali, alarm fatigue; (5) menyimpan raw data tanpa strategi agregasi → storage penuh tanpa insight.

IMPLEMENTASI PYTHON DI JUPYTER NOTEBOOK

Empat cell berikut menerapkan konsep pertemuan ini pada data sintesis yang meniru sensor industri. Lingkungan: conda env optoauto dengan paket numpy, pandas, matplotlib, scipy, statsmodels; notebook p1_pengantar_time_series.ipynb. Gambar 8 menunjukkan potongan Cell 3 yang menghitung lima statistik dasar.

Cell 1: Generate & Visualisasi Deret Waktu

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
np.random.seed(42)

# Simulasi vibration sensor pada motor - sampling 1 kHz, durasi 2 detik
fs = 1000          # Hz, sampling rate
T = 2.0           # detik
N = int(fs*T)     # jumlah sampel
t = np.linspace(0, T, N, endpoint=False)

# Sinyal getaran: 3 komponen frekuensi + noise gaussian
f1, f2, f3 = 25, 60, 120      # Hz
A1, A2, A3 = 1.0, 0.5, 0.25
x = (A1*np.sin(2*np.pi*f1*t) + A2*np.sin(2*np.pi*f2*t)
      + A3*np.sin(2*np.pi*f3*t) + np.random.normal(0, 0.15, N))
plt.plot(t[:200], x[:200]); plt.xlabel('t (s)'); plt.ylabel('amplitudo'); plt.show()
```

Cell 2: Efek Sampling Rate & Aliasing

```
f_signal = 50          # Hz, sinyal asli
T = 0.1               # detik (5 periode)
t_cont = np.linspace(0, T, 10000)
sig_cont = np.sin(2*np.pi*f_signal*t_cont)

# Tiga skenario: under-sampled, tepat Nyquist, oversampled
for fs_i, lbl in [(60, 'Under (60 Hz) → ALIASING'),
                  (100, 'Tepat Nyquist (100 Hz)'),
                  (500, 'Oversampled (500 Hz)')]:
    n_i = int(fs_i*T)
    t_i = np.linspace(0, T, n_i, endpoint=False)
    plt.plot(t_i, np.sin(2*np.pi*f_signal*t_i), 'o-', label=lbl)
plt.plot(t_cont, sig_cont, 'k--', alpha=.4, label='kontinu'); plt.legend(); plt.show()
```

Cell 3: Lima Statistik Dasar


```
mean_val = np.mean(x)
```



```

rms_val = np.sqrt(np.mean(x**2))
std_val = np.std(x)
peak_val = np.max(np.abs(x))
cf_val = peak_val / rms_val
print(f"Mean : {mean_val:8.4f} (AC signal → mendekati 0)")
print(f"RMS : {rms_val:8.4f} (energi efektif; basis ISO 10816)")
print(f"Std : {std_val:8.4f} (mean 0 → mendekati RMS)")
print(f"Peak : {peak_val:8.4f}")
print(f"CF : {cf_val:8.4f} (sinus murni 1.41; >4 = impulsif)")

```



```

cell3_statistik.py

mean_val = np.mean(x)

rms_val = np.sqrt(np.mean(x**2))

std_val = np.std(x)

peak_val = np.max(np.abs(x))

cf_val = peak_val / rms_val

print(f"RMS : {rms_val:.4f}")

print(f"CF : {cf_val:.4f}")

```

Gambar 8. Potongan Cell 3: perhitungan lima statistik dasar sinyal dengan NumPy.

Cell 4: Dekomposisi Visual Komponen

```

# Deret harian 1 tahun: tren + musiman mingguan + noise
N = 365; t = np.arange(N)
trend = 0.05*t
seasonal = 3.0 * np.sin(2*np.pi*t/7)
noise = np.random.normal(0, 0.5, N)
y = 20 + trend + seasonal + noise
dates = pd.date_range('2025-01-01', periods=N, freq='D')
series = pd.Series(y, index=dates, name='sensor_harian')
fig, ax = plt.subplots(4, 1, sharex=True, figsize=(9, 7))
for a, (nm, v) in zip(ax, [('observasi', y), ('tren', 20+trend),
                           ('musiman', seasonal), ('noise', noise)]):
    a.plot(dates, v); a.set_ylabel(nm)
plt.tight_layout(); plt.show()


```

TUGAS PERTEMUAN 1

Tugas dikerjakan melalui halaman LMS interaktif (tab Tugas) dan divalidasi otomatis oleh server. Struktur: 10 soal pilihan ganda (@1 poin), 10 soal komputasi easy-medium (@2 poin), dan 5 soal komputasi hard (@4 poin), dengan total 50 poin. Soal komputasi dikerjakan di Jupyter Notebook lalu kode ditempel ke LMS untuk dijalankan dan dinilai.

Distribusi poin ditunjukkan pada Gambar 9. Teks soal di bawah ini disalin persis dari halaman LMS (tab Tugas), termasuk seluruh opsi jawaban dan hint komputasi.

Distribusi 50 poin Tugas Pertemuan 1



Gambar 9. Distribusi 50 poin Tugas Pertemuan 1 berdasarkan tipe soal.

A. Pilihan Ganda (10 × 1 poin)

- **MC01:** Karakteristik utama yang membedakan time series dari data tabular biasa adalah...
 - (A) Time series selalu memiliki lebih banyak baris data
 - (B) Urutan observasi terhadap waktu adalah informasi yang harus dipertahankan
 - (C) Time series wajib mengandung kolom kategori
 - (D) Time series hanya berasal dari sensor industri
- **MC02:** Sebuah sensor mengambil data dengan sampling rate $f_s = 1000$ Hz. Periode samplingnya (Δt) adalah...
 - (A) 1 detik per sampel
 - (B) 1 ms per sampel ($\Delta t = 1/f_s = 0.001$ s)
 - (C) 1 μ s per sampel
 - (D) 1 menit per 1000 sampel
- **MC03:** Menurut Teorema Nyquist-Shannon, untuk merekonstruksi sebuah sinyal dengan frekuensi maksimum f_{maks} tanpa distorsi, sampling rate harus minimal...
 - (A) $f_s = f_{maks}$
 - (B) $f_s \geq 2 \cdot f_{maks}$
 - (C) $f_s = 0.5 \cdot f_{maks}$
 - (D) $f_s = (f_{maks})^2$
- **MC04:** Sebuah sinyal getaran 80 Hz disampling pada sampling rate 100 Hz. Yang akan terjadi adalah...

- (A) Sinyal terekam dengan sempurna karena $f_s > f_{\text{signal}}$
- (B) Aliasing: sinyal tampak sebagai frekuensi palsu (di bawah Nyquist)
- (C) Amplitudo terlihat $2\times$ lebih besar dari aslinya
- (D) Phase shift 90° tanpa perubahan amplitudo
- **MC05:** Frekuensi Nyquist (f_N) untuk sampling rate 10 kHz adalah...
 - (A) 10 kHz
 - (B) 20 kHz
 - (C) 5 kHz ($f_N = f_s / 2$)
 - (D) 1 kHz
- **MC06:** Komponen time series yang memiliki periode TETAP dan terkait kalender/jadwal (misalnya pola harian shift kerja, mingguan weekend) disebut...
 - (A) Tren (Trend)
 - (B) Musiman (Seasonal)
 - (C) Siklik (Cyclic)
 - (D) Residual / Noise
- **MC07:** Untuk sinyal AC seperti getaran (yang berosilasi sekitar nol), nilai yang lebih bermakna sebagai ukuran "energi efektif" sinyal adalah...
 - (A) Mean (μ): karena sinyal AC mean-nya ≈ 0 , ini tidak informatif
 - (B) RMS (Root Mean Square): menangkap energi rata-rata
 - (C) Median: robust tapi tidak terkait energi
 - (D) Mode: tidak meaningful untuk sinyal kontinu
- **MC08:** Crest Factor ($CF = \text{peak}/\text{RMS}$) yang TINGGI (>4) pada sinyal vibration bearing menandakan...
 - (A) Bearing dalam kondisi normal: CF tinggi adalah baseline sehat
 - (B) Sensor butuh kalibrasi karena drift
 - (C) Adanya impulsive event seperti spalling pada raceway bearing
 - (D) Sinyal terlalu lemah untuk dianalisis
- **MC09:** Menurut ISO 10816 untuk machine class I (motor <15 kW), RMS getaran < 0.71 mm/s diklasifikasikan sebagai...
 - (A) Unsatisfactory: perlu monitoring intensif
 - (B) Unacceptable: stop produksi segera
 - (C) Baik (Good): kondisi mesin sehat
 - (D) Class boundary: tidak bisa dikategorikan
- **MC10:** Untuk monitoring vibration bearing high-speed yang dapat mencapai frekuensi sinyal 5 kHz, sampling rate yang direkomendasikan praktek industri (dengan margin keamanan) adalah...
 - (A) 1 kHz: cukup untuk overview

- (B) 5 kHz: tepat di Nyquist boundary
- (C) 25–50 kHz: oversampling 5–10× untuk margin & anti-aliasing filter design
- (D) 1 MHz: lebih tinggi selalu lebih baik

B. Komputasi Easy–Medium (10 × 2 poin)

- **C1:** Hitung mean (rata-rata) dari deret x dataset referensi. Untuk sinyal AC murni $\text{mean} \approx 0$. Cetak nilai dengan `print(np.mean(x))`.
 -  **HINT:** Mean dihitung dengan `np.mean()` atas deret x . Untuk sinyal AC murni nilainya mendekati nol.
- **C2:** Hitung RMS (Root Mean Square) dari x : $\text{RMS} = \sqrt{(1/N) \cdot \sum x^2}$. Untuk sinyal getaran ini, RMS adalah ukuran energi efektif. Cetak nilai RMS.
 -  **HINT:** RMS = akar dari rata-rata kuadrat sinyal; gunakan `np.sqrt` dan `np.mean` pada x^{**2} .
- **C3:** Hitung standar deviasi (σ) dari x menggunakan `np.std(x, ddof=1)` (sample std). Untuk sinyal AC dengan $\text{mean} \approx 0$, $\sigma \approx \text{RMS}$.
 -  **HINT:** Gunakan `np.std(x, ddof=1)` untuk sample standard deviation; untuk $\text{mean} \approx 0$ hasilnya mendekati RMS.
- **C4:** Hitung Peak (nilai absolut maksimum) dari x : $\text{peak} = \max(|x|)$. Peak menangkap lonjakan tertinggi sinyal.
 -  **HINT:** Peak = nilai absolut maksimum; kombinasikan `np.abs` dengan `np.max` atas x .
- **C5:** Hitung Crest Factor ($\text{CF} = \text{peak} / \text{RMS}$) dari x . Sinyal sinusoidal murni: $\text{CF} = \sqrt{2} \approx 1.41$. Sinyal multi-frekuensi normal: $\text{CF} \approx 2\text{-}3$.
 -  **HINT:** Crest Factor = Peak ÷ RMS; bagi hasil peak (soal C₄) dengan hasil RMS (soal C₂).
- **C6:** Hitung frekuensi Nyquist untuk sampling rate $f_s = 10000$ Hz. Cetak nilai dalam Hz: $f_N = f_s / 2$.
 -  **HINT:** Frekuensi Nyquist = $f_s \div 2$. Substitusikan sampling rate dari soal.
- **C7:** Hitung periode sampling (Δt) dalam milisekon untuk sampling rate $f_s = 1000$ Hz. $\Delta t = 1/f_s$ dalam detik, kalikan 1000 untuk dapat ms.
 -  **HINT:** $\Delta t = 1 \div f_s$ (detik); kalikan 1000 untuk milisekon. Masukkan f_s dari soal.
- **C8:** Hitung jumlah sampel total yang dihasilkan oleh sensor dengan sampling rate $f_s = 2000$ Hz selama durasi 5 detik. Rumus: $N = f_s \times T$.
 -  **HINT:** $N = f_s \times T$; kalikan sampling rate dengan durasi dari soal, lalu konversi ke integer.

- **C9:** Hitung RMS dari sebuah sinusoidal MURNI dengan amplitudo $A = 2.0$ (tanpa noise). Rumus teoritis: $RMS = A/\sqrt{2}$. Verifikasi dengan generate sinyal: $x = 2.0 \cdot \sin(2\pi \cdot 10 \cdot t)$ selama 1 detik dengan $fs=1000$.
 - **HINT:** RMS sinusoidal murni $= A \div \sqrt{2}$. Generate sinyal dengan `np.linspace` dan `np.sin`, lalu verifikasi dengan formula RMS numerik.
- **C10:** Hitung Signal-to-Noise Ratio (SNR) dalam dB dari sinyal dengan power signal $P_s = 100$ dan power noise $P_n = 1$. Rumus: $SNR_{dB} = 10 \cdot \log_{10}(P_s/P_n)$.
 - **HINT:** $SNR_{dB} = 10 \times \log_{10}(P_s \div P_n)$; pakai `np.log10` dengan power signal dan noise dari soal.

C. Komputasi Hard (5 × 4 poin)

- **C11:** Implementasikan perhitungan RMS teoritis dari sinyal multi-frekuensi berdasarkan amplitudonya (rumus Parseval). Untuk dataset referensi (3 sinusoid $A_1=1.0$, $A_2=0.5$, $A_3=0.25$ + noise $\sigma=0.15$), gunakan formula: $RMS_{total} = \sqrt{(\sum(A_i^2/2) + \sigma^2_{noise})}$. Bandingkan dengan RMS empiris (numerik) dari deret x . Cetak nilai RMS teoritis.
 - **HINT:** Tiap sinusoid menyumbang power $A_i^2/2$; jumlahkan semua kontribusi ditambah variansi noise (σ^2), lalu akarkan untuk RMS total. Bandingkan dengan RMS numerik `np.sqrt(np.mean(x**2))`.
- **C12:** Implementasikan demonstrasi aliasing dari awal. Generate sinyal 50 Hz murni dengan resolusi tinggi (5000 sampel/detik selama 0.1 detik) → kemudian sampel-ulang pada frekuensi under-Nyquist 60 Hz. Hitung frekuensi alias yang muncul menggunakan rumus: $f_{alias} = |f_{signal} - k \cdot f_{s_{under}}|$ untuk k integer terdekat. Untuk $f=50$ Hz, $f_s=60$ Hz, alias muncul di...
 - **HINT:** Generate sinyal kontinu beresolusi tinggi, lalu downsample ke f_s under-Nyquist. Frekuensi alias $= |f_{signal} - k \cdot f_s|$ dengan k integer terdekat (gunakan `round`); verifikasi posisi peak dengan FFT pada hasil downsample.
- **C13:** Implementasikan Rolling RMS dari awal (tanpa `pandas`) pada dataset referensi x . Window = 256 sampel. Untuk tiap posisi i : hitung RMS dari window $x[i:i+256]$. Cetak nilai maksimum dari rolling RMS (deteksi window dengan energi tertinggi).
 - **HINT:** Geser window selebar 256 sampel di sepanjang x (loop atau list comprehension), hitung RMS tiap window dengan `np.sqrt(np.mean)`, lalu ambil nilai maksimumnya. Aplikasi: deteksi window dengan event abnormal di vibration monitoring.
- **C14:** Implementasikan identifikasi periode sinyal periodik menggunakan autokorelasi (ACF) dari awal. Generate sinyal test: `np.random.seed(7)`; $N=1000$; $sig = np.\sin(2\pi \cdot t/50) + 0.2 \cdot \text{noise}$ dengan periode TRUE = 50. Hitung ACF normalized, cari

indeks lag pertama setelah lag 5 dimana ACF mencapai puncak lokal; ini estimasi periode. Cetak nilai estimasi periode.

- 💡 **HINT:** Center sinyal (kurangi mean), hitung autokorelasi dengan `np.correlate` mode 'full' lalu ambil sisi positif dan normalisasi terhadap lag 0. Cari puncak lokal pertama setelah lag 5 dengan membandingkan tiap `acf[i]` terhadap tetangganya; indeks itu adalah estimasi periode.
- **C15:** Hitung Total Harmonic Distortion (THD) dari dataset referensi. THD adalah rasio RMS semua harmonik (A_2, A_3) terhadap RMS fundamental (A_1), dalam persen. Rumus: $THD\% = \sqrt{(\sum A_n^2/2)} / (A_1/\sqrt{2}) \times 100\%$ untuk $h \geq 2$. Cetak nilai THD dalam persen.
 - 💡 **HINT:** RMS fundamental = $A_1/\sqrt{2}$; RMS harmonik = $\sqrt{(\sum A_n^2/2)}$ untuk $h \geq 2$. $THD\% = (\text{RMS harmonik} \div \text{RMS fundamental}) \times 100$. Aplikasi: THD penting di power quality monitoring motor.

FORUM DISKUSI: STUDI KASUS

Rendi, junior engineer di pabrik komponen otomotif, ditugaskan menyiapkan sistem vibration monitoring pertama untuk 8 motor induksi 11 kW pada line CNC machining. Manajemen ingin mulai sederhana: baseline statistik time series plus alert, tanpa machine learning dulu. Karakteristik frekuensi yang harus terdeteksi: unbalance $1 \times \text{rpm} = 24 \text{ Hz}$, misalignment $2 \times \text{rpm} = 48 \text{ Hz}$, bearing fault $BPFI \approx 121 \text{ Hz}$ / $BPFO \approx 78 \text{ Hz}$, gear mesh sampai $\pm 1,5 \text{ kHz}$. DAQ mendukung maksimal 50 kHz (16-bit), tetapi penyimpanan terbatas: 15 hari raw di edge, setelah itu hanya agregat statistik harian.

- **Diskusi 1:** Berapa sampling rate yang direkomendasikan, dan mengapa? Pertimbangkan frekuensi maksimum yang harus terdeteksi, margin oversampling untuk desain anti-aliasing filter, serta trade-off penyimpanan dan bandwidth.
- **Diskusi 2:** Statistik time series mana yang wajib dihitung dan disimpan, pada window berapa lama? Timbang cakupan diagnostik (banyak metrik) versus kesederhanaan pemantauan harian.
- **Diskusi 3:** Rancang sistem alert rule-based berbasis ISO 10816 (threshold RMS untuk Class I: $< 0,71$ baik; $0,71-1,8$ satisfactory; $1,8-4,5$ unsatisfactory; $> 4,5$ unacceptable), crest factor sebagai indikator spalling, dan konsep persistence untuk mencegah false alarm dari spike sesaat.

Jawaban ditulis pada tab Forum LMS (minimal 30 kata per pertanyaan) dan akan tampil sebagai diskusi kelas.

DAFTAR PUSTAKA

- Altaf, M., Akram, T., Khan, M. A., Iqbal, M., Ch, M. M. I., & Hsu, C.-H. (2022). A new statistical features based approach for bearing fault diagnosis using vibration signals. *Sensors*, 22(5), 2012. <https://doi.org/10.3390/s22052012>
- Dudek, G. (2023). STD: A seasonal-trend-dispersion decomposition of time series. *IEEE Transactions on Knowledge and Data Engineering*, 35(10), 10339–10350. <https://doi.org/10.1109/TKDE.2023.3268125>
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>
- Romanssini, M., de Aguirre, P. C. C., Compassi-Severo, L., & Girardi, A. G. (2023). A review on vibration monitoring techniques for predictive maintenance of rotating machinery. *Eng*, 4(3), 1797–1817. <https://doi.org/10.3390/eng4030102>
- Tiboni, M., Remino, C., Bussola, R., & Amici, C. (2022). A review on vibration-based condition monitoring of rotating machinery. *Applied Sciences*, 12(3), 972. <https://doi.org/10.3390/app12030972>
- Ul Hassan, I., Panduru, K., & Walsh, J. (2024). An in-depth study of vibration sensors for condition monitoring. *Sensors*, 24(3), 740. <https://doi.org/10.3390/s24030740>
- Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are transformers effective for time series forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121–11128. <https://doi.org/10.1609/aaai.v37i9.26317>